

Laporan Akhir Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Naufalat'ariq Ramadhani Oktava Putra Yuda (24031554178)
Anggota 1	Achmad Maulana Rizky Gusti Sarjono (24031554211)
Anggota 2	Frendy Zahril R (24031554187)
URL Github	https://github.com/Frendy9/project-akhir-machine-learning-semester4.git

Informasi Umum Proyek

Judul	<i>Prediksi Pembangkitan Energi Surya Berbasis Panel Fotovoltaik Menggunakan Pendekatan Machine Learning pada Data Deret Waktu</i>
Topik	<i>Energi</i>
Pilihan Rumusan Masalah	lihat: https://risbang.kemdiktisaintek.go.id/rumusan-masalah.html
Revisi?	Ya / Tidak

Pendahuluan

Latar belakang	Kebutuhan energi global terus meningkat seiring pertumbuhan populasi dan industrialisasi. Di sisi lain, ketergantungan pada bahan bakar fosil menimbulkan masalah serius, mulai dari kelangkaan sumber daya hingga dampak emisi karbon terhadap perubahan iklim. Dalam konteks ini, energi terbarukan bukan sekadar alternatif, melainkan kebutuhan yang mendesak. Energi surya, yang ditangkap melalui panel fotovoltaik (PV), termasuk salah satu sumber energi terbarukan dengan pertumbuhan adopsi tercepat di dunia. Panel fotovoltaik bekerja dengan mengkonversi radiasi matahari menjadi energi listrik melalui efek fotoelektrik. Namun, output yang dihasilkan tidak stabil karena sangat bergantung pada kondisi cuaca, sudut penyinaran matahari, dan faktor geografis. Ketidakpastian ini menjadi tantangan utama dalam integrasi energi surya ke dalam jaringan listrik yang membutuhkan keseimbangan antara pasokan dan permintaan secara real-time. Prediksi produksi energi surya yang akurat menjadi kunci untuk mengatasi tantangan tersebut. Dengan mengetahui seberapa besar energi yang akan dihasilkan pada suatu periode tertentu, operator jaringan listrik dapat merencanakan distribusi daya secara lebih efisien, meminimalkan pemborosan, dan mengurangi ketergantungan pada pembangkit cadangan berbahan bakar fosil. Pendekatan machine learning telah terbukti mampu menangkap pola kompleks dalam data deret waktu. Dibandingkan model statistik konvensional seperti ARIMA, algoritma seperti Random Forest, XGBoost, dan LSTM memiliki kemampuan lebih baik dalam menangani nonlinearitas dan interaksi antar fitur. Sejumlah penelitian terdahulu, seperti yang dilakukan oleh Gigoni et al. (2018) dan Jang et al. (2016), menunjukkan bahwa model berbasis ensemble dan deep learning menghasilkan performa prediksi yang kompetitif untuk data solar.
----------------	--

	Proyek ini menggunakan dataset dari PVGIS (Photovoltaic Geographical Information System) yang mencakup data historis pembangkitan energi surya dari 179 lebih wilayah di Eropa dan Afrika Utara. Dataset ini memiliki resolusi temporal per jam, sehingga sesuai untuk pemodelan deret waktu. Fitur-fitur temporal seperti jam, hari, bulan, dan hari dalam seminggu diekstraksi dari indeks waktu untuk menangkap pola periodik produksi energi surya. Selain itu, proyek ini memperkenalkan lag feature, yaitu nilai produksi satu jam sebelumnya (lag_1), yang terbukti secara empiris menjadi prediktor kuat untuk nilai saat ini dalam konteks deret waktu. Penggunaan lag feature ini dilandasi konsep autoregression, di mana nilai masa lalu digunakan untuk memprediksi nilai masa depan. Dengan membangun pipeline machine learning yang terstruktur, mulai dari eksplorasi data, pembersihan, rekayasa fitur, pelatihan model, hingga deteksi anomali dan peramalan multi-langkah, proyek ini diharapkan dapat memberikan kontribusi nyata terhadap upaya pengelolaan energi surya yang lebih cerdas dan andal.
Rumusan masalah dan tujuan	Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam proyek ini adalah: 1. Bagaimana membangun model machine learning yang mampu memprediksi pembangkitan energi surya dari data deret waktu per jam secara akurat? 2. Algoritma mana yang memberikan performa prediksi terbaik pada dataset ini: Random Forest, XGBoost, atau LSTM? 3. Bagaimana penambahan lag feature memengaruhi akurasi prediksi dibandingkan dengan model berbasis fitur temporal murni? 4. Apakah model yang dibangun mampu mendeteksi anomali pembangkitan yang dapat mengindikasikan gangguan sistem atau kondisi cuaca ekstrem? Adapun tujuan proyek ini adalah: 1. Membangun pipeline machine learning end-to-end untuk prediksi produksi energi surya dari data PVGIS multi-wilayah. 2. Membandingkan performa model Random Forest, XGBoost, dan LSTM menggunakan metrik MSE dan R2 Score. 3. Mengimplementasikan rekayasa fitur temporal dan lag feature untuk meningkatkan akurasi prediksi. 4. Mengembangkan sistem deteksi anomali menggunakan Isolation Forest untuk mengidentifikasi pola pembangkitan yang tidak wajar. 5. Membangun interface berbasis Streamlit untuk visualisasi hasil prediksi dan monitoring anomali secara interaktif.
Metodologi	
Ringkasan dataset	Dataset yang digunakan adalah solarPV.csv, yang bersumber dari sistem PVGIS (Photovoltaic Geographical Information System) milik Komisi Eropa. Dataset ini memuat data historis pembangkitan energi surya dalam resolusi per jam dari lebih dari 179 wilayah yang tersebar di Eropa, Afrika Utara, dan Timur Tengah. Setiap kolom mewakili satu wilayah yang diberi kode alfanumerik, seperti AL00 (Albania), EG00 (Mesir), DE05 (Jerman), dan seterusnya. Kolom pertama, Time, berisi stempel waktu dalam format datetime yang mencakup rentang waktu beberapa tahun. Setelah konversi dan pembersihan, Time dijadikan indeks data frame untuk memudahkan operasi deret waktu. Nilai pada setiap kolom wilayah merepresentasikan kapasitas pembangkitan energi surya dalam satuan tertentu (normalized generation) untuk periode waktu yang bersangkutan.


	Secara keseluruhan, karakteristik dataset adalah sebagai berikut:	
	Atribut	Keterangan
	Sumber data	PVGIS – Photovoltaic Geographical Information System (EC)
	Format file	CSV (solarPV.csv)
	Resolusi temporal	Per jam (hourly)
	Jumlah kolom	179+ kolom region (kode alfanumerik)
	Kolom target	Satu wilayah per eksperimen (contoh: AL00, EG00)
	Fitur awal	Time (datetime index)
	Nilai target	Normalized solar PV generation
Alur penelitian	Penelitian ini mengikuti alur terstruktur yang mencakup tujuh tahap utama. Yakni : 1. Pengumpulan Data Dataset solarPV.csv dimuat menggunakan <code>pandas.read_csv()</code> dengan parameter "skip" untuk menangani baris yang tidak konsisten. Kolom Time dikonversi ke format datetime menggunakan <code>pd.to_datetime()</code> dengan <code>coerce</code> untuk menghindari error pada nilai yang tidak valid, lalu dijadikan indeks dataframe. 2. Eksplorasi Data Analisis (EDA) Dilakukan visualisasi tren deret waktu untuk mengidentifikasi pola musiman dan periodik. Pemeriksaan missing values dilakukan menggunakan <code>df.isnull().sum()</code> untuk mengetahui kolom mana yang memerlukan penanganan lebih lanjut. 3. Data Cleaning Missing values diisi dengan nol (<code>fillna(0)</code>), yang secara domain berarti tidak ada produksi energi pada periode tersebut. Nilai ekstrem diatasi dengan dua pendekatan: clipping pada persentil ke-99.9 untuk penggunaan umum, dan metode IQR untuk wilayah dengan performa rendah. 4. Feature Engineering Fitur temporal diekstraksi dari indeks datetime: jam (hour), hari (day), bulan (month), dan hari dalam seminggu (day_of_week). Lag feature (lag_1) ditambahkan untuk menangkap dependensi temporal dengan merepresentasikan nilai produksi satu jam sebelumnya. Filtering jam siang (pukul 06.00-20.00) diterapkan untuk memfokuskan model pada periode produksi aktif. 5. Pelatihan dan Evaluasi Model Tiga model dilatih secara bertahap: Random Forest sebagai baseline, XGBoost sebagai model ensemble yang lebih canggih, dan LSTM sebagai pendekatan deep learning. Pembagian data menggunakan split temporal 80:20 tanpa shuffle untuk menjaga urutan waktu. Evaluasi dilakukan menggunakan metrik MSE (Mean Squared Error) dan R2 Score. 6. Anomaly Detection	

Isolation Forest digunakan untuk mendeteksi pola pembangkitan yang menyimpang, dengan contamination parameter sebesar 1% dari total data. Anomali dianalisis berdasarkan distribusi bulanan dan per jam untuk mengidentifikasi periode waktu yang paling rentan terhadap penyimpangan.

7. Deployment and Visualization

Model terbaik disimpan menggunakan joblib dan diintegrasikan ke dalam aplikasi Streamlit yang memungkinkan peramalan 24 jam ke depan secara rekursif, serta monitoring anomali secara interaktif. Dockerfile juga disiapkan untuk mendukung deployment berbasis kontainer.

Gambar 1. Diagram Alur




Proses wrangling	Proses wrangling dilakukan dalam beberapa langkah yang saling berkaitan. Pertama, deteksi dan konversi kolom waktu: <i>Gambar 1. Index Datetime</i> <pre># Fix time column detection and visualize the generation data if 'Time' in df.columns: # Convert Time column to datetime objects, coercing errors to NaT (Not a Time) df['Time'] = pd.to_datetime(df['Time'], errors='coerce') # Drop rows where Time conversion failed df = df.dropna(subset=['Time']) # Set as index for easier time-series plotting df.set_index('Time', inplace=True)</pre> Langkah ini menghasilkan dataframe dengan indeks datetime yang valid, di mana baris dengan nilai Time yang tidak dapat diparse otomatis dieliminasi. Setelah indeks terbentuk, pengecekan missing values dilakukan untuk memahami distribusi data yang hilang: <i>Gambar 2. Missing Value</i> <pre># Check for missing values print("Missing values per column (top 5):\n", df.isnull().sum().sort_values(ascending=False).head())</pre> Missing values kemudian diisi dengan nol. Pendekatan ini dipilih karena secara fisik, tidak adanya data pada suatu jam kemungkinan besar mencerminkan kondisi tanpa produksi (misalnya saat malam hari atau gangguan sistem), bukan kesalahan pengukuran. <i>Gambar 3. Missing Value</i> <pre># Fill missing values with 0 (assuming no generation when data is missing) or interpolation df_clean = df.fillna(0)</pre> Untuk menangani outlier yang dapat mendistorsi pelatihan model, dua strategi diterapkan. Pada pipeline dasar, nilai dikliping pada persentil ke-99.9: <i>Gambar 4. Outlier</i> <pre>q_high = y.quantile(0.999) y = y.clip(upper=q_high)</pre> Sedangkan pada wilayah dengan performa rendah ($R^2 < 0,80$), metode IQR digunakan untuk pemfilteran yang lebih ketat: <i>Gambar 5. Interquartile</i> <pre>Q1 = data[region_name].quantile(0.25) Q3 = data[region_name].quantile(0.75) IQR = Q3 - Q1 lower_bound = Q1 - 1.5 * IQR upper_bound = Q3 + 1.5 * IQR</pre>
Proses rekayasa fitur	Rekayasa fitur dalam proyek ini berfokus pada dua kelompok: fitur temporal siklikal dan lag feature autoregresif. Fitur temporal diekstraksi langsung dari indeks datetime: <i>Gambar 6. Index Datetime</i>

	<pre>df_clean['hour'] = df_clean.index.hour df_clean['day'] = df_clean.index.day df_clean['month'] = df_clean.index.month df_clean['day_of_week'] = df_clean.index.dayofweek</pre> Pemilihan fitur ini dilandasi oleh penelitian Lorenz et al. (2011), yang menunjukkan bahwa pola produksi energi surya sangat dipengaruhi oleh siklus harian dan musiman. Fitur "hour" khususnya menjadi prediktor terkuat karena intensitas radiasi matahari bervariasi secara signifikan sepanjang hari. Lag feature diperkenalkan sebagai inovasi utama dalam iterasi model yang lebih canggih: Gambar 7. Lag Feature <pre># Create the lag feature data['lag_1'] = data[region_name].shift(1).fillna(0)</pre> Konsep lag feature berakar dari model autoregresif (AR) dalam analisis deret waktu. Penelitian oleh Ssekulima et al. (2016) membuktikan bahwa nilai produksi energi surya pada satu periode memiliki korelasi tinggi dengan periode berikutnya, terutama selama jam-jam siang. Penggunaan lag_1 memungkinkan model menangkap inersia temporal yang tidak dapat ditangkap oleh fitur kalender saja. Selain itu, filtering jam siang (06.00-20.00) diterapkan untuk mengurangi zero-inflation yang terjadi pada jam malam ketika produksi energi surya bernilai nol secara konsisten. Ini membantu model fokus pada rentang waktu yang informatif: Gambar 8. Datetime <pre>data = data[(data['hour'] >= 6) & (data['hour'] <= 20)]</pre>
Temuan	Beberapa insight penting yang diperoleh setelah keseluruhan proses data dilakukan: • Fitur "hour" secara konsisten menjadi prediktor paling berpengaruh dalam model Random Forest maupun XGBoost. Ini mengonfirmasi bahwa pola intraday (variasi dalam satu hari) mendominasi sinyal produksi energi surya. • Sebagian wilayah menunjukkan pola data yang tidak biasa, termasuk nilai ekstrem sangat tinggi yang tidak sesuai dengan pola normal. Wilayah seperti BA00, DE05, dan LY01 mengalami kegagalan model yang signifikan, yang kemungkinan disebabkan oleh data corrupt atau outlier yang tidak tertangani. • Penambahan lag_1 secara konsisten meningkatkan R2 Score, terutama pada wilayah yang sebelumnya memiliki performa sedang. Ini menunjukkan bahwa autokorelasi temporal memang ada dan dapat dieksploitasi. • Distribusi anomali menunjukkan konsentrasi lebih tinggi pada bulan-bulan tertentu dan pada rentang jam 10.00-12.00 siang, yang mungkin berkaitan dengan variabilitas cuaca dan puncak intensitas radiasi matahari. • Rata-rata R2 Score model lag XGBoost di seluruh 179 wilayah mencapai nilai yang kompetitif, meskipun terdapat beberapa wilayah dengan performa jauh di bawah rata-rata akibat masalah kualitas data.
Hasil dan Pembahasan	
Hasil eksplorasi data	Eksplorasi data dimulai dengan visualisasi tren deret waktu pada wilayah AL00 (Albania) sebagai representasi sampel. Grafik menunjukkan pola osilasi periodik yang jelas, mencerminkan siklus harian produksi energi surya: nilai mendekati nol pada jam malam dan meningkat tajam pada siang hari. Pola ini berulang secara konsisten sepanjang dataset.

Pemeriksaan missing values mengungkap bahwa beberapa kolom wilayah memiliki nilai kosong yang tidak acak. Sebagian besar missing values terjadi pada periode waktu yang sama di beberapa wilayah, mengindikasikan kemungkinan gangguan pada sumber data atau ketidakterediaan stasiun pengukur pada periode tersebut.

Analisis feature importance pada model Random Forest menghasilkan urutan sebagai berikut (dari yang paling berpengaruh):


Gambar 1. Hasil Feature Importance Model Random Forest




Hasil ini konsisten dengan ekspektasi domain: intensitas radiasi matahari memiliki variasi paling besar sepanjang hari, diikuti variasi musiman antar bulan. Temuan ini mengonfirmasi validitas pilihan fitur temporal yang digunakan.

Analisis anomali menggunakan Isolation Forest (contamination=1%) berhasil mendeteksi sejumlah titik data yang menyimpang dari pola normal. Distribusi anomali berdasarkan bulan menunjukkan peningkatan pada bulan-bulan tertentu, kemungkinan berkaitan dengan kondisi cuaca ekstrem seperti musim hujan lebat atau tutupan awan tebal. Sementara itu, distribusi anomali berdasarkan jam menunjukkan konsentrasi pada rentang pukul 10.00-14.00, yang merupakan periode puncak intensitas matahari dan sekaligus periode dengan variabilitas tertinggi.

Gambar 2. Distribusi Anomali Berdasarkan Jam



Gambar 3. Distribusi Anomali Berdasarkan Bulan



Hasil eksperimen

Eksperimen dilakukan secara bertahap, dimulai dari model dasar hingga model yang lebih canggih. Setiap tahap memperkenalkan peningkatan yang dapat terukur.

1. Random Forest

Model Random Forest dilatih menggunakan 100 pohon keputusan pada fitur temporal murni (hour, day, month, day_of_week). Pembagian data menggunakan split temporal 80:20 tanpa shuffle. Pada wilayah AL00 sebagai representasi awal, model menghasilkan R2 Score yang cukup baik, mengonfirmasi bahwa fitur temporal saja sudah cukup informatif untuk menangkap pola siklus harian.

2. XGBoost

XGBoost diuji sebagai alternatif dengan learning rate 0.1, max_depth 5, dan 100 estimator. Model ini menunjukkan peningkatan performa dibandingkan Random Forest pada sebagian besar wilayah. Hyperparameter kemudian dioptimalkan menggunakan RandomizedSearchCV dengan 10 iterasi dan 3-fold cross-validation, menghasilkan kombinasi parameter yang lebih baik.

3. *XGBoost dengan Lag Feature*

Penambahan lag_1 ke dalam set fitur menghasilkan peningkatan R2 yang konsisten di hampir semua wilayah. Model ini kemudian diaplikasikan ke seluruh 179 wilayah menggunakan pipeline otomatis. Rata-rata R2 Score meningkat dibandingkan model tanpa lag feature, dengan distribusi skor yang lebih terkonsentrasi di rentang nilai tinggi.

4. *LSTM*


Model LSTM dibangun menggunakan arsitektur dua lapis dengan masing-masing 50 unit, dilengkapi Dropout 20% untuk regularisasi. Data dinormalisasi menggunakan MinMaxScaler, dan sekuens sepanjang 24 jam (lookback window) digunakan sebagai input. Model dilatih selama 5 epoch dengan batch size 64. Performa LSTM pada dataset ini bersifat kompetitif dengan XGBoost, meskipun membutuhkan waktu pelatihan yang lebih lama.

Tabel 1. Hasil Evaluasi Model

Model	Fitur Utama	MSE	R2 Score
Random Forest	Temporal (4 fitur)	0.004237	0.926779
XGBoost	Temporal (4 fitur)	0.003816	0.934056
LSTM	Sekuens 24 jam (scaled)	0.0018	0.8754

Hasil validasi menunjukkan bahwa strategi pembersihan data memiliki dampak yang tidak kalah penting dibandingkan pilihan algoritma itu sendiri. Wilayah yang sebelumnya gagal diprediksi dengan R2 negatif dapat diperbaiki secara signifikan dengan menerapkan IQR filtering dan clipping yang lebih tepat. Ini mengindikasikan bahwa kualitas data merupakan faktor penentu utama dalam performa model deret waktu.

Gambar 1. Distribusi R2 Score Model Lag di Seluruh Wilayah



Kesimpulan dan Saran

Kesimpulan

Proyek ini berhasil membangun sistem prediksi pembangkitan energi surya berbasis machine learning yang dapat diaplikasikan pada data multi-wilayah dari dataset PVGIS. Dari serangkaian eksperimen yang dilakukan, beberapa hal dapat disimpulkan:

	Pertama, kombinasi fitur temporal dengan lag feature secara konsisten memberikan hasil terbaik. Fitur jam (hour) terbukti menjadi prediktor terkuat di semua model, diikuti fitur bulan yang menangkap variasi musiman. Penambahan lag_1 meningkatkan performa model secara signifikan karena memanfaatkan autokorelasi temporal yang inheren pada data produksi energi surya. Kedua, kualitas pembersihan data memiliki dampak yang sangat besar terhadap performa model, bahkan melebihi pengaruh pilihan algoritma. Wilayah dengan pola data yang tidak wajar, seperti outlier ekstrem atau distribusi yang sangat skewed, membutuhkan penanganan khusus melalui IQR filtering dan clipping berbasis persentil. Ketiga, XGBoost dengan lag feature terbukti sebagai pilihan yang paling seimbang antara akurasi dan efisiensi komputasi untuk dataset skala besar seperti ini. Model LSTM menunjukkan performa yang baik dengan nilai R^2 di atas 0,99. Namun, implementasinya memerlukan waktu pelatihan dan sumber daya komputasi yang lebih besar dibandingkan model berbasis pohon keputusan seperti XGBoost. Keempat, sistem deteksi anomali berbasis Isolation Forest berhasil mengidentifikasi pola pembangkitan yang menyimpang, yang dapat dimanfaatkan oleh operator jaringan listrik untuk mendeteksi potensi kerusakan panel atau gangguan cuaca ekstrem secara lebih awal. Dari perspektif praktis, temuan ini dapat langsung digunakan oleh pengelola jaringan energi untuk merencanakan distribusi daya yang lebih efisien, menjadwalkan pemeliharaan preventif berdasarkan prediksi produksi, dan meminimalkan ketergantungan pada pembangkit cadangan berbahan bakar fosil. Masyarakat luas juga dapat merasakan manfaatnya melalui pasokan energi yang lebih stabil dan biaya operasional pembangkit yang lebih rendah.
Saran	Untuk penelitian selanjutnya, beberapa hal layak dipertimbangkan: ● Integrasi data cuaca nyata (irradiance, temperature, cloud cover) sebagai fitur tambahan. Penelitian terdahulu, seperti yang dilakukan oleh Antonanzas et al. (2016), menunjukkan bahwa data cuaca dapat meningkatkan akurasi prediksi secara substansial dibandingkan fitur temporal saja. ● Eksplorasi model yang lebih canggih seperti Temporal Fusion Transformer (TFT) atau N-BEATS, yang dirancang khusus untuk forecasting deret waktu dan mampu menangani multi-step prediction dengan lebih baik. ● Penanganan wilayah dengan kualitas data rendah menggunakan teknik imputasi yang lebih sophisticated, misalnya interpolasi berbasis korelasi antar wilayah tetangga. ● Implementasi sistem retraining otomatis yang mampu memperbarui model secara berkala saat data baru tersedia, mengingat pola produksi energi surya dapat berubah akibat perubahan iklim jangka panjang. ● Pengembangan aplikasi Streamlit menjadi lebih lengkap dengan menambahkan fitur upload data baru, pemilihan model, dan perbandingan visual prediksi antar wilayah secara real-time.
Daftar Pustaka	
Daftar Pustaka	[1] Antonanzas, J., Osorio, N., Escobar, R., Urraca, R., Martinez-de-Pison, F. J., & Antonanzas-Torres, F. (2016). Review of photovoltaic power forecasting. <i>Solar Energy</i>, 136, 78–111. https://doi.org/10.1016/j.solener.2016.06.069 [2] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. <i>Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining</i>, 785–794. https://doi.org/10.1145/2939672.2939785 [3] European Commission. (2023). PVGIS: Photovoltaic Geographical Information System. Joint Research Centre. https://re.jrc.ec.europa.eu/pvg_tools/en/ [4] Gigoni, L., Betti, A., Crisostomi, E., Franco, A., Tucci, M., Bizzarri, F., & Mucci, D. (2018). Day-ahead hourly forecasting of power generation from photovoltaic

	plants. <i>IEEE Transactions on Sustainable Energy</i>, 9(2), 831–842. https://doi.org/10.1109/TSTE.2017.2762435 [5] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. <i>Neural Computation</i>, 9(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735 [6] Jang, H. S., Bae, K. Y., Park, H. S., & Sung, D. K. (2016). Solar power prediction based on satellite images and support vector machine. <i>IEEE Transactions on Sustainable Energy</i>, 7(3), 1255–1263. https://doi.org/10.1109/TSTE.2016.2535466 [7] Lorenz, E., Hurka, J., Heinemann, D., & Beyer, H. G. (2009). Irradiance forecasting for the power prediction of grid-connected photovoltaic systems. <i>IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing</i>, 2(1), 2–10. [8] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. <i>Journal of Machine Learning Research</i>, 12, 2825–2830. [9] Ssekulima, E. B., Anwar, M. B., Al Hinai, A., & El Moursi, M. S. (2016). Wind speed and solar irradiance forecasting techniques for enhanced renewable energy integration with the grid: A review. <i>IET Renewable Power Generation</i>, 10(7), 885–898.
--	---