

Laporan Kemajuan Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Naufalat'ariq Ramadhani Oktava Putra Yuda (24031554178)
Anggota 1	Achmad Maulana Rizky Gusti Sarjono (24031554211)
Anggota 2	Frendy Zahril R (24031554187)
URL Github	https://github.com/Frendy9/project-akhir-machine-learning-semester4.git

Informasi Umum Proyek

Judul	Prediksi Pembangkitan Energi Surya Berbasis Panel Fotovoltaik Menggunakan Pendekatan Machine Learning pada Data Deret Waktu
Topik	Energi
Pilihan Rumusan Masalah	lihat: https://risbang.kemdiktisaintek.go.id/rumusan-masalah.html
Revisi?	Ya

Informasi Detil Dataset

Sumber dataset	Kaggle: Solar PV Generation Time Series (https://www.kaggle.com/datasets/mexwell/solar-pv-generation-time-series), bersumber dari PVGIS (Photovoltaic Geographical Information System) milik European Commission Joint Research Centre. Data merupakan simulasi output daya panel surya per jam berdasarkan data iradiasi satelit dan parameter meteorologi (2005–2020).
Deskripsi awal fitur dataset	1. Time – Timestamp per jam (format: YYYYMMDD:HHMM), tipe: String/Datetime. 2. P – Output daya sistem PV (Watt), tipe: Float (variabel target utama). 3. Gb(i) – Irradiansi sinar langsung pada bidang miring (W/m^2), tipe: Float. 4. Gd(i) – Irradiansi difus pada bidang miring (W/m^2), tipe: Float. 5. Gr(i) – Irradiansi pantulan tanah pada bidang miring (W/m^2), tipe: Float. 6. H_sun – Ketinggian matahari di atas horison (derajat), tipe: Float. 7. T2m – Suhu udara 2 meter di atas permukaan ($^{\circ}C$), tipe: Float. 8. WS10m – Kecepatan angin 10 meter di atas permukaan (m/s), tipe: Float. 9. Int – Flag rekonstruksi data (0=normal, 1=terinterpolasi), tipe: Integer (biner).
Detil-detil langkah pre-processing	1. Load dataset CSV (solarPV.csv) dan parsing kolom 'Time' sebagai datetime. 2. Sort data berdasarkan waktu dan set sebagai index. 3. Pilih kolom wilayah target (TARGET_COL = "UK00") sebagai variabel target. 4. Penanganan nilai null: interpolasi berbasis waktu (method="time"), diikuti backward fill. 5. Ekstraksi fitur temporal: hour, day, month, dayofweek, dan season dari indeks datetime. 6. Deteksi dan penanganan outlier menggunakan metode IQR ($1.5 \times$): nilai di luar batas diganti dengan NaN lalu diinterpolasi kembali. 7. Normalisasi kolom target menggunakan MinMaxScaler (skala 0–1). 8. Pembuatan sequence sliding window (LOOKBACK=24 jam, HORIZON=1 jam) menggunakan FEATURE_COLS: [target, hour, day, month, dayofweek]. 9. Pembagian data temporal train/val/test dengan rasio 70:15:15 tanpa shuffling.

Kemajuan Pengerjaan

Teknik yang digunakan	<i>LSTM (Long Short-Term Memory) – model utama untuk menangkap dependensi jangka panjang pada data deret waktu. GRU (Gated Recurrent Unit) – alternatif LSTM yang lebih ringan secara komputasi. Ensemble Stacking (XGBoost + LSTM) – kombinasi model berbasis pohon dan deep learning. Implementasi menggunakan TensorFlow/Keras dengan hyperparameter: LOOKBACK=24 jam, HORIZON=1 jam, BATCH_SIZE=64, EPOCHS=100 (dengan EarlyStopping dan ReduceLROnPlateau). Optimizer: Adam.</i>
Nilai metrik terakhir	<u><i>Proses pelatihan model belum dimulai. Saat ini proyek masih berada pada tahap preprocessing dan persiapan data pipeline. Metrik RMSE, MAE, dan R² akan diisi setelah proses training LSTM, GRU, dan Ensemble Stacking selesai dijalankan.</i></u>
Visualisasi grafik latih dan validasi	<i>Belum tersedia (proses training belum dimulai). Grafik loss latih dan validasi akan dilampirkan setelah model selesai dilatih. Saat ini tersedia visualisasi EDA: distribusi target, tren keseluruhan time-series, rata-rata per jam, rata-rata per bulan, boxplot per musim, dan boxplot per jam (dihasilkan oleh fungsi plot_edu dalam notebook).</i>
Temuan	<i>Temuan pada tahap preprocessing: (1) Dataset memiliki sparsity tinggi – kolom target (P/output daya) bernilai 0 pada malam hari, menyebabkan distribusi sangat imbalanced dengan rasio nol:non-nol sekitar 2:1 hingga 3:1. (2) Deteksi outlier IQR berhasil diimplementasikan dan nilai di luar batas diinterpolasi. (3) Periodicitas harian (pola jam) dan tahunan (pola musiman) terlihat jelas pada visualisasi EDA. Proses latih belum dimulai; rencana selanjutnya adalah melatih model LSTM, GRU, dan Ensemble Stacking, kemudian dilanjutkan dengan hyperparameter tuning menggunakan grid search atau Bayesian optimization.</i>