

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Naufalat'ariq Ramadhani Oktava Putra Yuda (24031554178)
Anggota 1	Achmad Maulana Rizky Gusti Sarjono (24031554211)
Anggota 2	Frendy Zahril R (24031554187)
URL Github	https://github.com/Frendy9/project-akhir-machine-learning-semester4.git

Informasi Umum Proyek

Judul	<i>Prediksi Pembangkitan Energi Surya Berbasis Panel Fotovoltaik Menggunakan Pendekatan Machine Learning pada Data Deret Waktu</i>
Topik	<i>Energi</i>
Pilihan Rumusan Masalah	lihat: https://risbang.kemdiktisaintek.go.id/rumusan-masalah.html
Revisi?	Ya / Tidak

Deskripsi Rumusan masalah	<i>Krisis energi dan perubahan iklim mendorong dunia untuk beralih ke sumber energi terbarukan, salah satunya energi surya berbasis panel fotovoltaik (PV). Indonesia sebagai negara tropis memiliki potensi iradiasi matahari yang sangat besar, namun pemanfaatannya masih belum optimal akibat ketidakpastian output daya yang dipengaruhi oleh kondisi cuaca, suhu, dan waktu. Permasalahan yang dihadapi adalah sulitnya memprediksi secara akurat jumlah energi yang dihasilkan panel surya dalam jangka pendek maupun menengah. Fluktuasi output PV menyebabkan ketidakstabilan pada jaringan listrik jika tidak dikelola dengan baik. Ketidadaan model prediksi yang andal membuat pengelola sistem energi kesulitan dalam perencanaan distribusi dan penyimpanan energi. Tantangan utama dalam penyelesaian masalah ini meliputi: (1) sifat deret waktu data PV yang bersifat nonstasioner dan sangat dipengaruhi musim, (2) kebutuhan model yang mampu menangkap pola temporal jangka panjang, serta (3) kebutuhan preprocessing yang cermat terhadap data dengan nilai nol dominan pada malam hari.</i>
Tujuan penelitian (Objectives)	● Melakukan eksplorasi dan analisis mendalam terhadap dataset deret waktu pembangkitan energi surya PV dari PVGIS. ● Melakukan preprocessing data mencakup penanganan nilai nol, normalisasi, dan pembuatan fitur temporal (jam, bulan, musim). ● Membangun dan melatih model machine learning (LSTM, GRU, atau Ensemble) untuk prediksi output daya PV per jam. ● Mengevaluasi performa model menggunakan metrik RMSE, MAE, dan R2. ● Menganalisis hasil prediksi dan memberikan rekomendasi model terbaik untuk aplikasi nyata sistem energi surya.
Referensi penelitian	https://doi.org/https://doi.org/10.1016/j.renene.2019.12.131 https://doi.org/10.1016/j.solener.2021.03.033 https://doi.org/10.1109/ACCESS.2021.3075768

Informasi Detil Dataset

Sumber dataset	Kaggle: Solar PV Generation Time Series URL: https://www.kaggle.com/datasets/mexwell/solar-pv-generation-time-series bersumber dari PVGIS (Photovoltaic Geographical Information System) milik European Commission Joint Research Centre. Data merupakan simulasi output daya panel surya per jam yang dihitung berdasarkan data iradiasi satelit dan parameter meteorologi.
Deskripsi awal fitur dataset	• <i>Time</i> yaitu Timestamp per jam (format: YYYYMMDD:HHMM). Tipe: String/Datetime. • <i>P</i> yaitu Output daya sistem PV (Watt). Tipe: Float. Variabel target utama. • <i>Gb(i)</i> yaitu Irradiansi sinar langsung (beam) pada bidang miring (W/m^2). Tipe: Float. • <i>Gd(i)</i> yaitu Irradiansi difus pada bidang miring (W/m^2). Tipe: Float. • <i>Gr(i)</i> yaitu Irradiansi pantulan tanah pada bidang miring (W/m^2). Tipe: Float. • <i>H_sun</i> yaitu Ketinggian matahari di atas horison (derajat). Tipe: Float. • <i>T2m</i> yaitu Suhu udara 2 meter di atas permukaan tanah ($^{\circ}C$). Tipe: Float • <i>WS10m</i> yaitu Kecepatan angin 10 meter di atas permukaan (m/s). Tipe: Float. • <i>Int</i> yaitu Flag rekonstruksi data (0 = normal, 1 = terinterpolasi). Tipe: Integer (biner).
Aspek khusus dari dataset	<i>Sparsity</i>: Data <i>P</i> (output daya) bernilai 0 pada malam hari (± 18 jam/hari dari 24 jam tergantung musim), sehingga sparsity efektif $\pm 50-75\%$ bergantung lokasi dan musim. <i>Imbalanced</i>: Distribusi nilai <i>P</i> sangat imbalanced karena dominasi nilai nol di malam hari. <i>Rasio data nol terhadap non-nol</i> diperkirakan $\pm 2:1$ hingga $3:1$. <i>Outlier</i>: Potensi outlier pada variabel iradiasi dan suhu akibat kondisi cuaca ekstrem. Perlu dilakukan deteksi IQR atau z-score. <i>Periodicitas</i>: Data memiliki periodisitas harian (24 jam) dan tahunan (musiman) yang kuat, relevan untuk pemodelan deret waktu. Data historis multi-tahun (kisaran 2005–2020 tergantung database PVGIS yang digunakan).

Rencana Metode

Teknik yang digunakan	1. <i>LSTM</i> (Long Short-Term Memory) yaitu model utama untuk menangkap dependensi jangka panjang dalam deret waktu. 2. <i>GRU</i> (Gated Recurrent Unit) yaitu alternatif <i>LSTM</i> yang lebih ringan secara komputasi. 3. <i>Ensemble Stacking</i> (XGBoost + <i>LSTM</i>) yaitu kombinasi model berbasis pohon dan deep learning untuk meningkatkan akurasi prediksi.
Alasan pemilihan teknik/algoritma	<i>LSTM</i> dan <i>GRU</i> dipilih karena arsitekturnya dirancang khusus untuk data sekuensial dan mampu mengingat konteks historis jangka panjang, yang sangat penting pada data deret waktu PV dengan pola musiman kuat. <i>Ensemble Stacking</i> menggabungkan keunggulan model gradient boosting (XGBoost) dalam menangkap fitur non-linear statis dengan kemampuan <i>LSTM</i> dalam memodelkan pola temporal, sehingga menghasilkan prediksi yang lebih robust. Ketiga metode ini telah terbukti unggul dalam berbagai studi prediksi daya surya pada literatur terkini
Langkah-langkah umum pengerjaan	1. <i>Pengumpulan & Eksplorasi Data</i>: Unduh dataset dari Kaggle, lakukan EDA (Exploratory Data Analysis) untuk memahami distribusi, tren, dan pola musiman. 2. <i>Preprocessing</i>: Parsing kolom waktu, pembuatan fitur temporal (jam, hari, bulan, musim), normalisasi MinMaxScaler, penanganan nilai nol dan outlier.

	3. <i>Pembuatan Sequence: Membentuk window sliding untuk input model sekuensial (misal window size 24 jam untuk prediksi 1 jam ke depan).</i> 4. <i>Pembagian Data: Train/validation/test split dengan rasio 70:15:15, mempertahankan urutan temporal.</i> 5. <i>Pelatihan Model: Latih LSTM, GRU, dan Ensemble secara terpisah dengan hyperparameter tuning menggunakan grid search atau Bayesian optimization.</i> 6. <i>Evaluasi: Hitung RMSE, MAE, dan R^2 pada data test. Bandingkan performa antar model.</i> 7. <i>Analisis Hasil: Visualisasi hasil prediksi vs aktual, analisis error per jam dan per musim. Metrik: RMSE (Root Mean Squared Error), MAE (Mean Absolute Error), R^2 (Coefficient of Determination).</i>
--	--